

PREGUNTAS 620454– Entrega 3 - Clasificación

1. ¿Por qué no es correcto aplicar encoding después de dividir en train/test?
2. ¿Qué problema ocurre si escalas usando todo el dataset antes del split?
3. ¿Por qué algunas variables no necesitan escalamiento?
4. ¿Qué diferencia hay entre variables categóricas binarias y nominales en encoding?
5. ¿Qué pasaría si no aplicas encoding en este dataset?
6. ¿Qué tipo de variables podrían generar problemas en Logistic Regression si no se transforman?
7. ¿Qué problema resuelve **GridSearchCV**?
8. ¿Qué pasaría si eliges mal la métrica en GridSearchCV?
9. ¿Por qué no usar accuracy como scoring en este problema?
10. ¿Qué significa que un modelo esté “overfitting”?
11. ¿Cómo detectas overfitting en GridSearchCV?
12. ¿Qué diferencia hay entre los modelos que usaron (LR vs Decision Tree)?
13. ¿Por qué Decision Tree puede sobreajustar más fácilmente?
14. ¿Qué hace el hiperparámetro max_depth?
15. ¿Qué hace el hiperparámetro C en Logistic Regression?
16. ¿Por qué es importante usar validación cruzada?
17. ¿Por qué accuracy es una mala métrica en este problema?
18. Explica con tus palabras qué significa recall en fraude
19. Explica qué significa precision en este contexto
20. ¿Qué pasa si tienes alto recall pero baja precision?
21. ¿Qué pasa si tienes alta precision pero bajo recall?
22. ¿Qué métrica priorizarías en fraude y por qué?
23. ¿Qué representa un falso negativo en este problema?
24. ¿Qué representa un falso positivo?
25. Interpreta los valores de la matriz de confusión de tu modelo
26. ¿Cuál es el error más grave en este problema?
27. ¿Qué ocurre si aumentan los falsos negativos?
28. ¿Qué ocurre si aumentan los falsos positivos?
29. ¿Cómo se relaciona la matriz de confusión con recall?
30. ¿Qué es el threshold en clasificación?
31. ¿Qué ocurre al bajar el threshold a 0.3?
32. ¿Qué ocurre al subir el threshold a 0.7?
33. ¿Por qué cambia el recall al modificar el threshold?
34. ¿Por qué cambia la precision al modificar el threshold?
35. ¿Por qué es necesario usar predict_proba para esto?
36. ¿Cuál fue el comportamiento de tus métricas al cambiar el threshold?

37. ¿Tu modelo siguió el comportamiento esperado? Explica
38. ¿Qué threshold elegirías si el costo del fraude fuera extremadamente alto?
39. ¿Qué threshold elegirías si la experiencia del cliente fuera prioritaria?